

1 Метод опорных векторов

Основная идея метода опорных векторов состоит, в построении линейного классификатора, задающего разделяющую поверхность, имеющую равный и максимальный отступ от обоих классов. Для реализации этой идеи, с учётом линейной неразделимости классов, необходимо решить задачу:

$$\min_{w, \xi \geq 0} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (1)$$

$$y_i(w^T x_i + w_0) \geq 1 - \xi_i, \quad i = 1 \dots n$$

Или, если учитывать неотрицательность ξ_i :

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i(w^T x_i + w_0)) \quad (2)$$

Где C – константа регуляризации, x_i – i -ый объект из обучающей выборки, y_i – метка класса i -ого объекта, n – количество объектов в обучающей выборке.

Воспользовавшись теоремой Куна-Таккера можно свести данную задачу к эквивалентной:

$$\max_{\lambda} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n y_i y_j \lambda_i \lambda_j (x_i, x_j) \quad (3)$$

$$0 \leq \lambda_i \leq C, \quad i = 1, \dots, n$$

$$\sum_{i=1}^n \lambda_i y_i = 0$$

Проблема заключается в том, что гиперплоскость часто не может правильно разделить выборку, поэтому можно попробовать преобразовать признаковое пространство для получения хорошо разделяемой выборки. Не трудно видеть, что для решения задачи 3 достаточно уметь считать скалярное произведение между преобразованными векторами. Скалярное произведение можно задать как ядерную функцию $K(x, y) = (\varphi(x), \varphi(y))$, где x, y вектора исходного пространства, φ некое преобразование на нём. В данных терминах задача 3 преобразовывается в:

$$\max_{\lambda} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i,j=1}^n y_i y_j \lambda_i \lambda_j K(x_i, x_j) \quad (4)$$

$$0 \leq \lambda_i \leq C, \quad i = 1, \dots, n$$

$$\sum_{i=1}^n \lambda_i y_i = 0$$

2 Реализация метода опорных векторов

2.1 Метод субградиентного спуска

2.1.1 Метод градиентного спуска

Метод градиентного спуска решает задачу поиска минимума функции, путём итерационного построения решения. На шаге 1 берётся первое приближение решения – w_0 . Пусть далее на шаге n построено решение w_n , тогда на шаге $n + 1$ будет построено решение:

$$w_{n+1} = w_n - \eta_n \nabla_w Q(w) \quad (5)$$

2.1.2 Сведение метода градиентного спуска к методу субградиентного спуска

Идея метода градиентного спуска состоит в том, чтобы искать минимум функции "спускаясь" по направлению антиградиента. К сожалению функция из 2 не является дифференцируемой всюду, а значит не имеет градиента в некоторых точках. Для этого вводится понятие субградиента:

Определение 1 Вектор $g \in \mathbf{R}^n$ называется субградиентом функции $f : \mathbf{R}^n \rightarrow \mathbf{R}$ в точке x , если $\forall z \in \mathbf{R}^n$ выполняется неравенство:

$$f(z) \geq f(x) + g^T(z - x) \quad (6)$$

Замечание 1.1 Если в точке $x_0 \exists$ градиент функции f , то субградиент функции f в точке x_0 совпадает с градиентом функции f в этой точке.

Согласно 1.1, достаточно найти субградиент функции в точках, где эта функция не имеет градиент. Для функции из 2 – это все такие, и только такие точки, для которых $1 - y_i(w^T x_i + w_0) = 0$, $i = 1 \dots n$. Для удобства допишем каждому объекту X_i слева 1. Для такой выборки имеем задачу:

$$\min_w \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max(0, 1 - y_i w^T x_i) \quad (7)$$

При этом w_0 оказывается «забит» в w . Докажем следующую теорему:

Теорема 1 Если у функций f_1 и f_2 существует субградиент в точке x_0 , то у их суммы также существует субградиент в точке x_0 причём:

$$\nabla^s f_1 + \nabla^s f_2 \subseteq \nabla^s (f_1 + f_2) \quad (8)$$

Доказательство.

$$\left. \begin{aligned} f_1(z) &\geq f_1(x) + g_1^T(z - x) \\ f_2(z) &\geq f_2(x) + g_2^T(z - x) \end{aligned} \right\} \Rightarrow (f_1 + f_2)(z) \geq (f_1 + f_2)(x) + (g_1 + g_2)^T(z - x)$$

■

Заметим, что в методе градиентного спуска градиент функции в точке определён однозначно, однако того же нельзя всегда сказать о субградиенте функции. Поэтому в методе субградиентного спуска, в случаях, где сохранена неоднозначность, мы будем брать только один вектор из субградиента. На основании этого, а также на основании теоремы 1, замечания 1.1 и общего вида функции из задачи 2 можно сделать вывод о том, что достаточно найти хотя бы один вектор, удовлетворяющий неравенству 6 для функции $f = 1 - y_i w_i^T x_i$ в точке w такой, что $1 - y_i w_i^T x_i = 0$. Найдём такой вектор:

$$\begin{aligned} 1 - y_i z^T x_i &\geq 1 - y_i w^T x_i + g^T(z - w) \\ 1 - y_i z^T x_i &\geq g^T z - g^T w \end{aligned} \quad (9)$$

Нетрудно видеть, что $g = -y_i x_i$ удовлетворяет неравенству 9. На основании вышеизложенного запишем формулу субградиента целевой функции $Q(w)$ для метода субградиентного спуска. Введём γ_i такую, что:

$$\gamma_i(w) = \begin{cases} 0, & \text{если } 1 - y_i w^T x_i < 0; \\ -y_i x_i, & \text{иначе.} \end{cases}$$

Тогда субградиент целевой функции $Q(w)$ равняется:

$$\nabla^s Q(w) = w + C \sum_{i=1}^n \gamma_i(w) \quad (10)$$

Осталось только заменить градиент в методе градиентного спуска (5) на подсчитанный выше субградиент (10).

2.2 Метод стохастического субградиентного спуска

Идея метода стохастического субградиента в том, чтобы считать субградиент не по всей выборке, а только по какой-либо её части, которая генерируется на каждой итерации случайно.

2.3 Методы внутренней точки

2.3.1 Введение

Для реализации метода внутренней точки была использована функция *cvxopt.solvers.qp*, решающая следующую задачу:

$$\begin{aligned} \min_x \quad & \frac{1}{2} x^T P x + q^T x \\ & Gx \preceq h \\ & Ax = b \end{aligned} \quad (11)$$

Где x – вектор столбец.

2.3.2 Метод внутренней точки для прямой задачи

Необходимо свести задачу 1 к задаче 11.

$$x = (w_0 \quad w_1 \quad \dots \quad w_l \quad \xi_1 \quad \xi_2 \quad \dots \quad \xi_n)^T$$

$$P = \begin{pmatrix} & & & & l+1 & & & \\ 0 & 0 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & 1 & 0 & \dots & 0 \\ 0 & 0 & 0 & \dots & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & 0 & 0 & \dots & 0 \end{pmatrix}$$

$$q = l + 2 \begin{pmatrix} 0 \\ \vdots \\ 0 \\ C \\ \vdots \\ C \end{pmatrix}$$

$$G = \begin{pmatrix} -y_1 & -1 & -x_1^1 & -x_1^2 & \dots & -x_1^l & -1 & -1 & \dots & -1 \\ -y_2 & -1 & -x_2^1 & -x_2^2 & \dots & -x_2^l & -1 & -1 & \dots & -1 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ -y_n & -1 & -x_n^1 & -x_n^2 & \dots & -x_n^l & -1 & -1 & \dots & -1 \\ 0 & 0 & 0 & 0 & \dots & 0 & -1 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & \dots & 0 & 0 & -1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & \dots & 0 & 0 & 0 & \dots & -1 \end{pmatrix}$$

$$h = \begin{pmatrix} -1 \\ -1 \\ \vdots \\ -1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$A, B = None$$

Очевидно, что при данных значениях параметров, функция 2.3.1 решает задачу 1. При этом нам нужны только w и w_0 . Поэтому данный подход не слишком эффективен.

2.3.3 Метод внутренней точки для двойственной задачи с линейным ядром

Решаем задачу 3. Сведём эту задачу к задаче 11.

$$x = (\lambda_1 \quad \lambda_2 \quad \dots \quad \lambda_n)^T$$

$$P = \begin{pmatrix} y_1 y_1(x_1, x_1) & y_1 y_2(x_1, x_2) & \dots & y_1 y_n(x_1, x_n) \\ y_2 y_1(x_2, x_1) & y_2 y_2(x_2, x_2) & \dots & y_2 y_n(x_2, x_n) \\ \dots & \dots & \dots & \dots \\ y_n y_1(x_n, x_1) & y_n y_2(x_n, x_2) & \dots & y_n y_n(x_n, x_n) \end{pmatrix}$$

$$q = (-1 \quad -1 \quad \dots \quad -1)^T$$

$$G = \begin{pmatrix} -1 & 0 & 0 & \dots & 0 \\ 0 & -1 & 0 & \dots & 0 \\ 0 & 0 & -1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & -1 \\ 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix}$$

$$h = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ C \\ C \\ \vdots \\ C \end{pmatrix}$$

$$A = (y_1 \quad y_2 \quad \dots \quad y_n)$$

$$b = (0)$$

При данных параметрах функция 11 решает задачу 3.

2.3.4 Метод внутренней точки для двойственной задачи с ядром rbf

Будем решать задачу 4 с rbf ядром. Это значит, что функция $K(x, y)$ в задаче 4 примет значение $e^{-\frac{1}{2\gamma}\|x-y\|^2}$. Для того, чтобы свести задачу 4 к задаче 11 достаточно взять такие же параметры, что и для случая с линейным ядром, но в матрице P поменять скалярное произведение (x_i, x_j) на значение rbf-ядра в этих точках.

2.4 Методы реализованные в библиотеках liblin и libsvm.

При решении задачи 1 и задачи 4 с rbf ядром использовались методы из классов *LinearSVC* и *SVC* соответственно, взятые из библиотеки *sklearn.svm*

2.5 Описание класса SVM

Для реализации описанных выше методов был создан класс SVM. Параметры инициализации:

C – константа регуляризации(число), по умолчанию 1.

method – название метода решения задачи SVM (строка). Принимает значения: «*subgradient*», «*stoch_subgradient*», «*primal*», «*dual*», «*liblinear*», «*libsvm*».

kernel – название ядра (строка). Только если *method* = «*dual*» или «*libsvm*». Принимает значения «*linear*» или «*rbf*»

gamma – параметр для rbf ядра (число). Только если *kernel* = «*rbf*».

Методы класса:

fit(tol=0.001, max_iter=10000, verbose=False, stop_criterion=«*objective*», batch_size=50, lamb=0.5, alpha=1, beta=1)

predict(X_test, return_classes=True) – возвращает вектор с метками классов для соответствующих объектов, если *return_classes* = True, и значение целевой функции (если *method* ≠ «*libsvm*» или «*liblinear*»)

compute_support_vectors(X) – возвращает опорные вектора (только если решалась двойственная задача)

compute_w(X, y) – если решалась двойственная задача находит вектор w и отступ w_0 для прямой задачи.

Атрибуты класса:

w – вектор $l \times 1$ коэффициентов разделяющей гиперплоскости.

w_0 – число, смещение разделяющей гиперплоскости.

A – вектор $n \times 1$ двойственных коэффициентов.

В двумерном случае возможна визуализация выборки при помощи функции *visualize*(X, y, alg_svm, show_vectors = False).